ÜNİTE

2

Sosyal Medyadan Veri Toplama: Web Scraping, API ve Veri Etiği

- Sosyal Medya Verisinin Anatomisi
- Dört Temel Veri Toplama Yaklaşımı
- Web Kazıma (Web Scraping)
- API Mimarisi, Yetkilendirme ve Kısıtlar
- API ile Web Scraping Karşılaştırması
- Veri Toplama Araçları
- KVKK, Veri Etiği ve Anonimleştirme
- Temel Kavramlar Sözlüğü

KampüsCepte · öğrenciler için ücretsiz ders notları

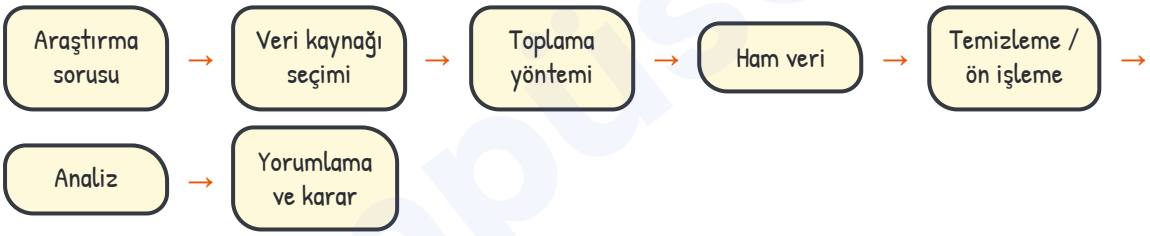
Sosyal medya analizi, verinin niteliği, toplanma biçimi ve hukuki sınırları belirlenmeden yapılamaz. Bu ünitede veriyi nereden ve nasıl toplayacağımızı, web kazıma ve API yöntemlerini, son olarak da veriyi toplarken uymamız gereken etik ve KVKK kurallarını öğreniyoruz.

2.1 Sosyal Medya Verisinin Anatomisi

Bir sosyal medya verisi yalnızca metin değildir; beş katmandan oluşur:

Katman	İçerdikleri
Metin içeriği	Gönderi gövdesi, başlık, yorum metni, açıklamalar
Kullanıcı profili bilgileri	Anonim/benzersiz kullanıcı ID'si, takipçi sayısı, hesap özellikleri
Etkileşim metrikleri	Beğeni, yorum sayısı, retweet/paylaşım, skor, kaydetme
Ağ ve ilişki bilgileri	Bahsetmeler (mentions), hashtagler, bağlantılar (URL)
Zaman ve üst veri (metadata)	Zaman damgası (timestamp), istemci cihaz, coğrafi konum

Veri odaklı araştırma yaşam döngüsü



Akılda tut: Her şey araştırma sorusuyla başlar; veri kaynağı ve toplama yöntemi bu soruya göre seçilir.

2.2 Dört Temel Veri Toplama Yaklaşımı

Yöntem	Nasıl yapılır?	Artısı / eksisi
1. Manuel toplama	Araştırmacı az sayıdaki veriyi elektronik tabloya elle girer.	Küçük örneklemde uygulanabilir; zaman maliyeti yüksek, insan hatasına açık.
2. API ile çekme	Platformun yetkilendirme kurallarıyla sunduğu resmi servisler kullanılır.	Yapılandırılmış veri doğrudan gelir; kota ve kurallara bağlıdır.
3. Web scraping	Web sayfasının HTML kodu yazılımla ayrıştırılıp veri otomatik ayıklanır.	Her görünen sayfaya uygulanabilir; kırılgandır, hukuki sınırları vardır.
4. İkincil / açık veri setleri	Kaggle, akademik arşivler, açık veri portallarındaki hazır setler kullanılır.	Hızlıdır; ama veri araştırma sorusuna tam uymayabilir.

2.3 Web Kazıma (Web Scraping)

Web scraping (web kazıma)

Bir tarayıcının insan için görüntülediği HTML sayfasını yazılımın (ör. Python betiğinin) doğrudan talep edip hedef etiketleri (DOM öğelerini) filtreleyerek veri tabanına kaydetmesidir.

Tarayıcı geliştirici araçları: Elements/Inspect ve Network

	Elements / Inspect	Network
Ne gösterir?	Sayfanın HTML hiyerarşisini (DOM ağacını)	Tarayıcı ile sunucu arasındaki tüm HTTP isteklerini
Ne için kullanılır?	Verinin durduğu h1, p, div etiketlerini ve class / id niteliklerini bulmak	İçeriğin sonradan JavaScript çağrılarıyla (XHR/Fetch) getirilip getirilmediğini anlamak
Scraping'e katkısı	Hangi etiketin hedefleneceğini söyler	Verinin hazır JSON olarak geldiği gizli uç noktayı gösterebilir

İpucu

Chrome'da sayfaya sağ tıklayıp İncele (Inspect) dediğinizde ya da F12'ye bastığınızda geliştirici araçları açılır.

Python ile web kazıma

Kütüphane / fonksiyon	Görevi
`requests`	Sunucuya HTTP GET veya POST isteği gönderip sayfanın kaynak kodunu indirir.
`BeautifulSoup4`	İndirilen HTML'i ayrıştırır (parse).
`find()`	Koşula uyan ilk etiketi döndürür.
`find_all()`	Koşula uyan tüm etiketleri liste olarak döndürür.
`select()`	CSS seçicisiyle etiket seçer (ör. `div.yorum`).

kazima.py

```python
import requests
from bs4 import BeautifulSoup

yanit = requests.get("https://ornek-forum.com/konu/42")
print(yanit.status_code)              # 200 ise istek başarılı

soup = BeautifulSoup(yanit.text, "html.parser")
baslik = soup.find("h1").text          # ilk h1 etiketi
yorumlar = soup.find_all("p", class_="yorum")   # tüm yorumlar
for y in yorumlar:
    print(y.text)
```

Örnek betik bir forum sayfasını indirir, başlığı ve `class="yorum"` olan bütün paragrafları çeker. Etiket ve class adları, sayfa Inspect ile incelenerek bulunur.

HTTP durum kodları (status codes)

Kod	Anlamı	Ne zaman görülür?
200	OK · İstek başarılı	Sayfa sorunsuz indi
403	Forbidden · Erişim reddedildi	Site bota izin vermiyor, yetki yok
404	Not Found · Kaynak bulunamadı	Yanlış adres, silinmiş sayfa
429	Too Many Requests · Aşırı istek	Hız sınırı (rate limit) aşıldı

2.4 API Mimarisi, Yetkilendirme ve Kısıtlar

API

İki farklı bilgi sisteminin standart protokoller üzerinden güvenli ve yapılandırılmış veri alışverişi yapmasını sağlayan arayüzdür.

KampüsCepte

REST API ve HTTP metotları

Metot / format	Görevi	Örnek
GET	Sunucudan veri okumak, listelemek	`GET /posts` → gönderileri getir
POST	Sunucuya yeni veri göndermek, kayıt oluşturmak	`POST /posts` → yeni gönderi oluştur
JSON	API yanıtlarındaki standart veri formatı; anahtar-değer (key-value) çiftleri	`"begeni": 412`

GET /posts/p_1842 · yanıt

```
{
  "id": "p_1842",
  "kullanici": "User_001",
  "metin": "Kargo yine gecikti",
  "zaman": "2026-11-03T21:14:00",
  "begeni": 412,
  "hashtagler": ["kargo", "şikayet"]
}
```

Yanıtta her bilgi bir anahtar (ör. `"begeni"`) ve bir değer (ör. `412`) çiftidir; makine tarafından hızlıca işlenir.

Authentication ve Authorization

	Authentication (Kimlik doğrulama)	Authorization (Yetkilendirme)
Sorduğu soru	"Sen kimsin?"	"Hangi verilere erişebilirsin?"
Nasıl?	İstemci API Key ya da Token ile kendini tanıtır	Doğrulanmış istemcinin erişebileceği veri sınırları belirlenir
Sıra	Önce gelir	Kimlik doğrulandıktan sonra gelir

Hız sınırı (rate limit)

Platformun sunucu aşırı yüklenmesini ve kötüye kullanımı önlemek için belirli bir zaman diliminde (dakika/saat) izin verdiği azami istek sayısıdır. Sınır aşılınca sunucu HTTP 429 Too Many Requests hatası döndürür.

2.5 API ile Web Scraping Karşılaştırması

Ölçüt	API	Web Scraping
Veri kaynağı	Platformun yetkilendirilmiş resmi uç noktası	İstemciye sunulan sitenin HTML sayfası
Veri biçimi	Yapılandırılmış, standart (JSON, XML)	Ayrıştırılması gereken ham HTML / DOM ağacı
Kararlılık	Yüksek; sürümlü, değişikliklere dayanıklı	Kırılgan; bir CSS/class adı değişince betik bozulur
Kısıtlar	Resmi kota ve süre sınırları (rate limit)	IP engelleme (ban), Captcha, sunucu blokajı
Hukuki güvence	Kullanım sözleşmesi ve izinli geliştirici çerçevesi	Sitenin Kullanım Koşulları (Terms of Service) ve telif sınırları

2.6 Veri Toplama Araçları

Araç	Ne işe yarar?
Reddit API + PRAW Python Reddit API Wrapper	Subreddit, gönderi başlıkları, kullanıcı puanı ve hiyerarşik yorum ağaçlarını (bir gönderi → çok yorum, 1:N) yapılandırılmış biçimde çeken resmi Python sarmalayıcısı
Tweepy	X (Twitter) resmi API v2 için kullanılan Python kütüphanesi
snscrape	Geçmişte X arayüzünü simüle ederek veri çekmek için kullanılan araç; platform kuralları değiştiği için güncelliği kontrol edilmelidir
Postman	Kod yazmadan önce API uç noktalarına test istekleri (GET, POST), başlık (header) ve token gönderip JSON yanıtlarını inceleyen API test aracı

2.7 KVKK, Veri Etiği ve Anonimleştirme

Sınavda dikkat

Bir verinin internette herkese açık olması, onun her amaçla sınırsızca kaydedilebileceği, satılabileceği ya da yayımlanabileceği anlamına gelmez.

6698 sayılı KVKK kavramı	Anlamı
Kişisel veri	Kimliği belirli veya belirlenebilir gerçek kişiye ilişkin her türlü veri: kullanıcı adı, gerçek isim, e-posta, fotoğraf, konum...
Veri minimizasyonu	Yalnızca araştırma sorusunun gerektirdiği asgari verinin toplanması; ilgisiz kişisel verilerin baştan dışlanması
Amaçla sınırlılık	Toplanan verinin yalnızca duyurulan araştırma kapsamında işlenmesi ve saklanması

Kullanıcı adı maskeleme (pseudonymization)

Ham veri	Raporda yazılacak
@ahmet123	User_001
@elif.yz	User_002
@kampus_haber	User_003

Raporlarda kullanıcı kimlikleri doğrudan paylaşılmaz; takma kodlar kullanılır.

Sınavda dikkat

Maskeleme tek başına yetmez: yaş, şehir, meslek gibi tekil bilgiler başka verilerle birleşince kişiyi ele verebilir. Buna yeniden tanımlama riski denir; ek güvenlik önlemleri alınmalıdır.

2.8 Temel Kavramlar Sözlüğü

Kavram	Tanım
Web scraping	Web sayfalarındaki verilerin programla HTML yapısından ayıklanması
REST API	HTTP standartlarını (GET, POST…) kullanarak istemci ile sunucu arasında veri alışverişi sağlayan mimari
Rate limit	API sunucusunun istemci başına belirli bir sürede kabul ettiği en fazla istek sayısı
BeautifulSoup	HTML/XML belgelerini ayrıştırıp etiket ve niteliklere göre veri ayıklayan Python kütüphanesi
PRAW	Reddit API ile çalışmak için geliştirilmiş Python sarmalayıcı paketi
JSON	Anahtar-değer çiftlerinden oluşan, insanca okunabilir, makinece kolay işlenen hafif veri formatı
Veri minimizasyonu	Yalnızca mutlak gerekli verilerin toplanmasını öngören veri koruma ilkesi
Postman	API isteklerini tasarlamak, test etmek ve yanıtlarını incelemek için kullanılan araç

KampüsCepte

2.9 Ünite Değerlendirme Soruları

Quiz formatı · 8 çoktan seçmeli · 6 doğru-yanlış · 5 eşleştirme · Süre: 20 dk

Bölüm I: Çoktan Seçmeli Sorular (1 – 8)

1. Bir araştırmacı az sayıda gönderiyi Excel'e elle girmektedir. Bu yöntemin en belirgin dezavantajı hangisidir?

A) Yapılandırılmış JSON üretmesi
B) Rate limit hatasına yol açması
C) Zaman maliyetinin yüksek ve insan hatasına açık olması
D) IP engellemesine yol açması
E) Kullanım koşullarını otomatik ihlal etmesi

2. Bir sayfadaki yorumların ilk yüklemede HTML'de olmadığı, sayfa açıldıktan sonra JavaScript ile sunucudan getirildiği nasıl anlaşılır?

A) Network sekmesinde XHR/Fetch isteklerini izleyerek
B) Postman ile POST isteği atarak
C) Sayfayı 404 hatasıyla yeniden yükleyerek
D) BeautifulSoup'ta find() yerine find_all() kullanarak
E) Elements sekmesinde yalnızca h1 etiketine bakarak

3. BeautifulSoup'ta `soup.find_all("p", class_="yorum")` komutu ne döndürür?

A) Sayfanın JSON yanıtını
B) Yalnızca etiket sayısını
C) Sayfadaki ilk yorum paragrafını
D) class'ı "yorum" olan tüm p etiketlerinin listesini
E) Sayfanın HTTP durum kodunu

4. Kısa sürede çok fazla istek gönderen bir veri toplama betiği hangi HTTP durum kodunu almayı en çok bekler?

A) 404
B) 429
C) 500
D) 200
E) 301

5. "Sen kimsin?" sorusunu cevaplayan ve istemcinin API Key ya da Token ile kendini tanıttığı süreç hangisidir?

A) Rate limit
B) Tokenization
C) Authorization
D) Pseudonymization
E) Authentication

KampüsCepte

6. Web scraping için aşağıdakilerden hangisi doğrudur?

A) Yalnızca Reddit için kullanılabilir

B) Veriyi platformun resmi uç noktasından JSON olarak alır

C) Sitedeki bir class adı değişince betik bozulabileceği için kırılgandır

D) Hiçbir hukuki sınırı yoktur

E) Rate limit ile hiç karşılaşmaz, IP engeli olmaz

7. Reddit'te bir gönderinin altındaki iç içe yorumları yapılandırılmış biçimde çekmek için kullanılan resmi Python sarmalayıcısı hangisidir?

A) PRAW **B)** snscrape **C)** WordCloud

D) Tweepy **E)** Postman

8. Bir araştırma yalnızca ürün yorumlarının duygu yönünü inceleyecekken kullanıcıların e-posta ve doğum tarihlerinin de toplanması hangi ilkeye aykırıdır?

A) Authentication **B)** Velocity **C)** Tokenization

D) Veri minimizasyonu **E)** Rate limit

Bölüm 2: Doğru / Yanlış Soruları (9 – 14)

İfade doğru ise parantez içine "D", yanlış ise "Y" yazınız.

9. ( ) İnternette herkese açık olan bir veri, KVKK açısından her amaçla sınırsızca kaydedilip yayımlanabilir.

10. ( ) API ile toplanan veri genellikle JSON veya XML gibi yapılandırılmış biçimde gelir.

11. ( ) GET metodu sunucuya yeni kayıt oluşturmak, POST metodu ise veri okumak için kullanılır.

12. ( ) Raporlarda @ahmet123 yerine User_001 yazılması kullanıcı adı maskelemeye (pseudonymization) örnektir.

13. ( ) Kullanıcı adları maskelendiğinde kişinin yeniden tanınma riski tamamen ortadan kalkar.

14. ( ) Postman, kod yazmadan önce API uç noktalarına test istekleri gönderip JSON yanıtlarını incelemek için kullanılır.

KampüsCepte

Bölüm 3: Eşleştirme Soruları (15 – 19)

Soldaki kavramları sağdaki açıklamalarla eşleştiriniz. Doğru harfi parantez içine yazınız.

Kavramlar	Açıklamalar
( ) 15. 403	A) Doğrulanmış istemcinin hangi verilere erişebileceğini belirleme
( ) 16. Elements / Inspect	B) Erişim reddedildi (Forbidden)
( ) 17. Kaggle	C) Verinin yalnızca duyurulan araştırma kapsamında işlenmesi
( ) 18. Authorization	D) Sayfanın HTML hiyerarşisini, etiketleri ve class/id niteliklerini gösteren sekme
( ) 19. Amaçla sınırlılık	E) İkincil / açık veri seti kaynağına örnek

KampüsCepte

2. ünite · Cevap Anahtarı ve Açıklamalar

1. C · **2.** A · **3.** D · **4.** B · **5.** E · **6.** C · **7.** A · **8.** D · **9.** Y · **10.** D · **11.** Y · **12.** D · **13.** Y · **14.** D · **15.** B · **16.** D · **17.** E · **18.** A · **19.** C

Soru	Doğru cevap	Açıklama
1	C) Zaman maliyetinin yüksek ve insan hatasına açık olması	—
2	A) Network sekmesinde XHR/Fetch isteklerini izleyerek	Network sekmesi tarayıcı–sunucu arasındaki tüm HTTP isteklerini, dinamik XHR/Fetch çağrılarını gösterir.
3	D) class'ı "yorum" olan tüm p etiketlerinin listesini	find() ilk eşleşeni, find_all() tümünü liste olarak verir.
4	B) 429	429 Too Many Requests = rate limit aşıldı.
5	E) Authentication	Authentication = kimlik doğrulama; Authorization = "neye erişebilirsin?"
6	C) Sitedeki bir class adı değişince betik bozulabileceği için kırılgandır	—
7	A) PRAW	—
8	D) Veri minimizasyonu	Sadece araştırma sorusunun gerektirdiği asgari veri toplanmalı.
9	YANLIŞ [Y]	Herkese açık olmak sınırsız kullanım izni demek değildir.
10	DOĞRU [D]	İfade doğrudur.
11	YANLIŞ [Y]	Tersi: GET okur/listeler, POST yeni veri gönderir.
12	DOĞRU [D]	İfade doğrudur.
13	YANLIŞ [Y]	Tekil bilgiler başka verilerle birleşince kişi tanınabilir (yeniden tanımlama riski).
14	DOĞRU [D]	İfade doğrudur.
15	B ile eşleşir	403 → Erişim reddedildi (Forbidden)
16	D ile eşleşir	Elements / Inspect → Sayfanın HTML hiyerarşisini, etiketleri ve class/id niteliklerini gösteren sekme
17	E ile eşleşir	Kaggle → İkincil / açık veri seti kaynağına örnek
18	A ile eşleşir	Authorization → Doğrulanmış istemcinin hangi verilere erişebileceğini belirleme
19	C ile eşleşir	Amaçla sınırlılık → Verinin yalnızca duyurulan araştırma kapsamında işlenmesi

KampüsCepte