ÜNİTE

3

# Metin Ön İşleme, NLP, Vektörizasyon ve Konu Modelleme


- Doğal Dil İşleme ve Metin Madenciliği
- Metin Ön İşleme Aşamaları
- Kök ve Gövde Bulma: Stemming ve Lemmatization
- Metin Vektörizasyonu
- Kelime Bulutu (WordCloud)
- Konu Modelleme ve LDA
- Python Ekosistemi ve Araçlar
- Temel Kavramlar Sözlüğü


kampuscepte.com.tr · öğrenciler için ücretsiz ders notları

Sosyal medyadan toplanan verilerin büyük bölümü serbest metindir: büyük/küçük harf tutarsızlıkları, noktalama, yazım hataları, emojiler, argo ve "çoook" gibi uzatmalar içerir. Bilgisayar bu metni olduğu gibi işleyemez. Bu ünitede metni temizlemeyi, sayıya çevirmeyi ve içindeki gizli konuları bulmayı öğreniyoruz.

## 3.1 Doğal Dil İşleme ve Metin Madenciliği

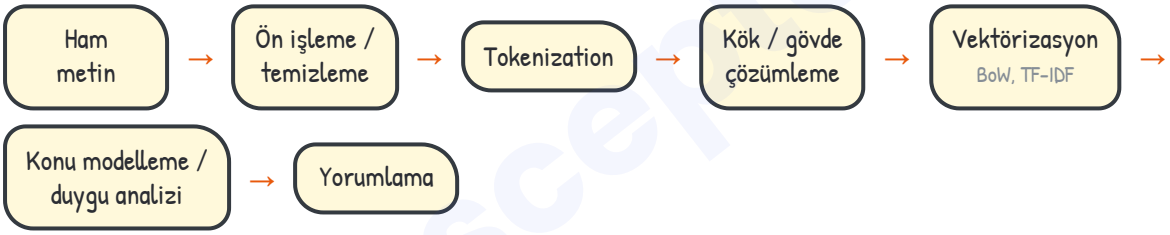
**Doğal Dil İşleme (NLP · Natural Language Processing)**

Bilgisayarların insan dilini kural tabanlı veya istatistiksel modellerle işlemesini, çözümlemesini ve yapılandırmasını sağlayan yöntemler bütünüdür.

**Metin madenciliği (Text Mining)**

Yapılandırılmamış metin yığınlarından örüntü, ana tema, ilişki ve işlenebilir içgörüler çıkarma sürecidir.

### Analitik iş akışı




## 3.2 Metin Ön İşleme Aşamaları

Modelin başarısı, ön işlemede verinin ne kadar iyi temizlendiğine bağlıdır.

| Adım | Ne yapılır? | Dikkat |
|---|---|---|
| 1. Küçük harfe çevirme | Aynı kelimenin farklı yazımları tekilleştirilir (HİÇ → hiç). | Marka/özel isim analizinde (Apple / apple) amaca uygunluğu düşünülmeli. |
| 2. Gürültü temizleme | URL'ler, kullanıcı etiketleri (@kullanici) ve özel noktalama silinir. | Hashtagde # silinir, kelime korunabilir. |
| 3. Emojiler | Genel sınıflandırmada gürültü sayılıp silinebilir. | Duygu analizinde korunmalı veya metne çevrilmeli (😡 → "kızgın"). |
| 4. Tokenization | Cümle en küçük anlamlı birimlere (token) ayrılır: kelime, karakter, alt kelime. | |
| 5. Stop words | Ayırt edici anlam taşımayan sık kelimeler silinir: ve, ile, için, de, da, bir, bu. | "değil", "hiç" gibi olumsuzluk sözcükleri silinirse duygu yönü tersine döner! |

### Örnek: bir tweet adım adım

| Aşama | Metin |
|---|---|
| Ham metin | @ahmet123 Bu telefonun bataryası HİÇ iyi DEĞİL 😡 https://t.co/x9 #hayalkırıklığı |
| 1. Küçük harf | @ahmet123 bu telefonun bataryası hiç iyi değil 😡 https://t.co/x9 #hayalkırıklığı |
| 2. URL ve @ silindi, # kaldırıldı | bu telefonun bataryası hiç iyi değil 😡 hayalkırıklığı |
| 3. Emoji metne çevrildi | bu telefonun bataryası hiç iyi değil [kızgın] hayalkırıklığı |
| 4. Tokenization | [bu] [telefonun] [bataryası] [hiç] [iyi] [değil] [kızgın] [hayalkırıklığı] |
| 5. Stop words ("bu") silindi | [telefonun] [bataryası] [hiç] [iyi] [değil] [kızgın] [hayalkırıklığı] |

**Sınavda dikkat**

Bu örnekte "hiç" ve "değil" silinseydi geriye "telefonun bataryası iyi" kalırdı ve olumsuz yorum olumlu görünürdü.

## 3.3 Kök ve Gövde Bulma: Stemming ve Lemmatization

Türkçe sondan eklemeli bir dildir: "gel-iyor-du-m", "gel-miş", "gel-ecek-ti". Aynı kelimenin onlarca biçimini ortak paydada toplamak için iki yöntem vardır:

| Ölçüt | Stemming (Gövdeleme / budama) | Lemmatization (Sözlük kökü / lemma) |
|---|---|---|
| Yöntem | Kural tabanlı ek kesme | Morfolojik ve dil bilgisel sözlük çözümlemesi |
| Çıktı | Çıkan gövde sözlükte olan gerçek bir kelime olmayabilir | Kelimenin sözlükteki anlamlı temel biçimi (gelmiş, gelecekti → gelmek) |
| Hız | Daha hızlı, kural bazlı | Daha fazla işlem gücü ve dil modeli ister |
| Türkçe araçlar | SnowballStemmer, NLTK tabanlı kesiciler | Zeyrek, Zemberek, spaCy / turkce-nlp |

| Kelime | Stemming (örnek çıktı) | Lemmatization |
|---|---|---|
| kitaplarımızdan | kitap | kitap |
| gelecekti | gelecek | gelmek |
| gidiyorlar | gidiyor | gitmek |

**Fark nerede?**

Stemming yalnızca sondaki ekleri keser; "gelecekti"deki -ecek ekini kesmediği için "gelecek" isim gibi kalır. Lemmatization kelimenin dil bilgisini çözümlediği için doğru kökü (gelmek) bulur.

## 3.4 Metin Vektörizasyonu

Algoritmalar metni doğrudan okuyamaz; metinler matematiksel uzayda sayısal vektörlere dönüştürülmek zorundadır.

### N-gram

**N-gram**

Metinde birbirini takip eden N adet kelimelik dizilerdir. Tek kelimelerin (unigram) bağlamı kaybettiği durumlarda kullanılır.

| Tür | N | "müşteri hizmetleri desteği iyi değil" cümlesinden örnek |
|---|---|---|
| Unigram | 1 | müşteri · hizmetleri · desteği · iyi · değil |
| Bigram | 2 | müşteri hizmetleri · … · iyi değil |
| Trigram | 3 | müşteri hizmetleri desteği · … · desteği iyi değil |

"iyi" ve "değil" ayrı ayrı olumlu/nötr görünür; bigram olarak "iyi değil" açık bir olumsuzluktur.

## Kelime torbası (Bag of Words · BoW)

Bütün belgelerdeki benzersiz kelimelerden bir sözlük çıkarılır; her belgenin bu kelimeleri kaç kez içerdiği bir matrise yazılır. Kelime sırası, sözdizimi ve anlam bağlamı dikkate alınmaz.

| Belge | Metin |
|---|---|
| B1 | kargo hızlı geldi |
| B2 | kargo geç geldi |
| B3 | batarya hızlı bitti |

| Belge | kargo | hızlı | geldi | geç | batarya | bitti |
|---|---|---|---|---|---|---|
| B1 | 1 | 1 | 1 | 0 | 0 | 0 |
| B2 | 1 | 0 | 1 | 1 | 0 | 0 |
| B3 | 0 | 1 | 0 | 0 | 1 | 1 |

**Neden torba?**

"kargo hızlı geldi" ile "geldi hızlı kargo" BoW'da aynı vektörü verir; çünkü kelime sırası tutulmaz. Bu, BoW'un torba adını almasının sebebidir.

## TF-IDF (Term Frequency – Inverse Document Frequency)

**TF-IDF**

Bir kelimenin yalnızca bir metinde ne kadar sık geçtiğini değil, bütün derlem (corpus) içinde ne kadar ayırt edici olduğunu ölçen istatistiksel ağırlıklandırma yöntemidir.

$$TF(t, d) = \frac{t \text{ teriminin } d \text{ belgesindeki frekansı}}{d \text{ belgesindeki toplam terim sayısı}}$$

$$IDF(t) = \log \frac{\text{Toplam belge sayısı } (N)}{t \text{ terimini içeren belge sayısı } (df_t)}$$

$$TF\text{-}IDF(t, d) = TF(t, d) \times IDF(t)$$

### Örnek: Yukarıdaki üç belgede TF-IDF

B1 = "kargo hızlı geldi" belgesindeki üç kelimenin TF-IDF değerini bulalım (N = 3, log tabanı 10).

| Terim (B1'de) | TF | $df_t$ | IDF = log(3/df) | TF-IDF |
|---|---|---|---|---|
| kargo | 1/3 | 2 (B1, B2) | log 1,5 ≈ 0,176 | 0,059 |
| hızlı | 1/3 | 2 (B1, B3) | log 1,5 ≈ 0,176 | 0,059 |
| geldi | 1/3 | 2 (B1, B2) | log 1,5 ≈ 0,176 | 0,059 |

B3'teki batarya kelimesi ise yalnızca 1 belgede geçer: IDF = log(3/1) ≈ 0,477, TF-IDF = 1/3 × 0,477 ≈ 0,159. Batarya, B3'ü diğer belgelerden ayırt eden kelimedir; skoru da daha yüksektir.

**Sınavda dikkat**

Bir terim incelenen belgede çok sık ama diğer belgelerde nadir geçiyorsa TF-IDF skoru yüksek çıkar: o kelime belgeyi temsil etme gücü yüksek, ayırt edici bir kelimedir. Her belgede geçen bir kelimenin IDF'si log(N/N) = log 1 = 0'dır.

## 3.5 Kelime Bulutu (WordCloud)

Kelime bulutu, metinde en sık geçen kelimelerin büyük yazılarak görselleştirilmesidir. Aşağıda telefon yorumlarından çıkarılmış örnek bir bulut var:




**Sınavda dikkat**

WordCloud bir hipotez testi ya da derin analiz aracı değildir; yalnızca keşifsel veri analizinde (EDA) ilk bakış için kullanılır. Bağlamdan, kelime ilişkilerinden ve duygu yönünden yoksundur: "batarya" büyük görünür ama övülüyor mu, şikâyet mi ediliyor, buluttan anlaşılmaz.

# 3.6 Konu Modelleme ve LDA

**Konu modelleme (Topic Modeling)**

Etiketlenmemiş büyük metin derlemlerindeki gizli tematik yapıları ve ana konuları gözetimsiz (unsupervised) öğrenmeyle otomatik keşfeden istatistiksel yöntemdir.

**LDA (Latent Dirichlet Allocation)**

En yaygın konu modelleme algoritmasıdır. İki varsayıma dayanır: (1) Her belge birden fazla konunun karışımıdır. (2) Her konu, belirli kelimelerin belirli olasılıklarla bir araya gelmesiyle tanımlanır.

## Örnek: Telefon yorumlarında LDA çıktısı (k = 3)

| Konu | Modelin verdiği kelime kümesi | Araştırmacının verdiği başlık |
|---|---|---|
| Konu 1 | şarj · batarya · tükenme · ısınma | *Batarya sorunları* |
| Konu 2 | kargo · geç · paket · teslimat | *Teslimat şikâyetleri* |
| Konu 3 | kamera · gece · fotoğraf · net | *Kamera kalitesi* |

**Sınavda dikkat**

LDA konulara başlık atamaz. Yalnızca birlikte görülme olasılığı en yüksek kelime kümelerini üretir. Kümeyi yorumlayıp "Batarya sorunları" gibi bir başlık koymak araştırmacının uzmanlığına bağlıdır.

**k nasıl seçilir?**

Konu sayısı k önceden seçilir. Seçerken tutarlılık skoru (coherence score) ve konuların yorumlanabilirliği ölçüt alınır.

# 3.7 Python Ekosistemi ve Araçlar

| Araç | Ne için kullanılır? |
|---|---|
| NLTK & spaCy | Tokenization, stop-word temizliği, n-gram, POS (sözcük türü) etiketleme |
| Zeyrek / Zemberek | Türkçe morfolojik analiz, kök ayıklama, lemmatization |
| Scikit-Learn | `CountVectorizer` (BoW), `TfidfVectorizer` (TF-IDF), `LatentDirichletAllocation` (LDA) |
| WordCloud | Frekans ağırlıklı kelime bulutu |
| Orange Data Mining | Kod yazmadan, sürükle-bırak bloklarıyla görsel metin analizi |

## Orange'da metin analizi akışı




vektor.py

```python
from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer

belgeler = ["kargo hızlı geldi", "kargo geç geldi", "batarya hızlı bitti"]

bow = CountVectorizer().fit_transform(belgeler)      # Kelime torbası
tfidf = TfidfVectorizer().fit_transform(belgeler)    # TF-IDF ağırlıkları
print(bow.toarray())
```

kampuscepte.com.tr

## 3.8 Temel Kavramlar Sözlüğü

| Kavram | Tanım |
|---|---|
| Tokenization | Metnin kelime, n-gram veya karakter bazlı en küçük analiz birimlerine ayrılması |
| Stop words | Sık kullanılan ama tek başına ayırt edici anlam taşımayan işlevsel kelimeler |
| Stemming | Kelime sonundaki eklerin kural tabanlı kesilerek gövdeye indirgenmesi |
| Lemmatization | Kelimenin dil bilgisel biçimi çözümlenerek sözlükteki temel köke dönüştürülmesi |
| N-gram | Metinde peş peşe gelen N sözcüğün oluşturduğu bağlamsal öbek |
| TF-IDF | Terim frekansı ile ters belge sıklığını çarparak kelimenin göreli ayırt ediciliğini ölçen metrik |
| Topic Modeling (LDA) | Belge-konu ve konu-kelime olasılıklarını hesaplayarak gizli temaları çıkaran gözetimsiz model |

kampuscepte.com.tr

# 3.9 Ünite Değerlendirme Soruları

*Quiz formatı · 8 çoktan seçmeli · 6 doğru-yanlış · 5 eşleştirme · Süre: 20 dk*

## Bölüm I: Çoktan Seçmeli Sorular (1 – 8)

**1.** Duygu analizi yapılacak bir derlemde stop-words listesinden "değil" kelimesinin dikkatsizce silinmesinin sonucu ne olur?

A) Emojiler metne çevrilir
B) Lemmatization hızlanır
C) Tokenization yapılamaz
D) Cümlenin duygu yönü tersine dönebilir
E) TF-IDF skorları sıfırlanır

**2.** Duygu analizi çalışmasında emojiler için en doğru yaklaşım hangisidir?

A) Gürültü sayılıp mutlaka silinmeleri
B) Korunmaları veya metin etiketine dönüştürülmeleri
C) URL'ye çevrilmeleri
D) Stop word olarak işaretlenmeleri
E) Yalnızca hashtag içindekilerin silinmesi

**3.** "gelmiş" ve "gelecekti" kelimelerini sözlükteki "gelmek" biçimine indiren yöntem hangisidir?

A) Bag of Words
B) N-gram
C) Stemming
D) Tokenization
E) Lemmatization

**4.** Stemming için aşağıdakilerden hangisi doğrudur?

A) Daha fazla işlem gücü ve dil modeli ister
B) Çıkan gövde her zaman sözlükte yer alan gerçek bir kelimedir
C) Kural tabanlı ek kesme yaptığı için daha hızlıdır
D) Zemberek ve Zeyrek yalnızca stemming yapar
E) Kelime sırasını korur

**5.** Bag of Words modeli için aşağıdakilerden hangisi söylenemez?

A) Kelime sırasını ve anlam bağlamını dikkate alır
B) Metni sayısal vektöre çevirir
C) Scikit-Learn'de CountVectorizer ile uygulanır
D) Belgelerdeki benzersiz kelimelerden sözlük oluşturur
E) Her belgenin kelimeleri kaç kez içerdiğini matrise döker

**6.** 10 belgelik bir derlemde "kargo" kelimesi 10 belgenin hepsinde geçmektedir. Bu kelimenin IDF değeri (log tabanı 10) kaçtır?

A) Hesaplanamaz
B) 1
C) 10
D) 0
E) 0,1


kampuscepte.com.tr · öğrenciler için ücretsiz ders notları

**7.** LDA ile ilgili aşağıdakilerden hangisi doğrudur?

**A)** Her belgenin tek bir konudan oluştuğunu varsayar

**B)** Kelime kümeleri üretir; başlığı araştırmacı belirler

**C)** Konu sayısı k'yı kendisi kesin olarak bulur

**D)** Konulara doğrudan "Müşteri Şikâyeti" gibi başlıklar atar

**E)** Gözetimli öğrenme yöntemidir, etiketli veri ister

**8.** Kelime bulutu (WordCloud) için aşağıdakilerden hangisi bir sınırlılıktır?

**A)** Python'da kolayca üretilebilir

**B)** Frekans ağırlıklıdır

**C)** Sık geçen kelimeleri büyük gösterir

**D)** Keşifsel analizde ilk bakış sağlar

**E)** Kelimelerin hangi duygu yönünde kullanıldığını göstermez

## Bölüm 2: Doğru / Yanlış Soruları (9 – 14)

*İfade doğru ise parantez içine "D", yanlış ise "Y" yazınız.*

**9.** (  ) Hashtag temizlenirken # sembolü silinip kelimenin kendisi korunabilir.

**10.** (  ) "iyi değil" ifadesinin olumsuzluğunu yakalamak için unigram, bigramdan daha uygundur.

**11.** (  ) Bir terim bir belgede sık, diğer belgelerde nadir geçiyorsa TF-IDF skoru yüksek çıkar.

**12.** (  ) Konu modelleme, etiketlenmemiş metinlerdeki gizli temaları gözetimsiz öğrenmeyle keşfeder.

**13.** (  ) Orange Data Mining, metin analizi için mutlaka Python kodu yazmayı gerektirir.

**14.** (  ) Marka analizinde (Apple / apple) her metni küçük harfe çevirmek her zaman doğru bir tercihtir.

kampuscepte.com.tr

## Bölüm 3: Eşleştirme Soruları (15 – 19)

*Soldaki kavramları sağdaki açıklamalarla eşleştiriniz. Doğru harfi parantez içine yazınız.*

| Kavramlar | Açıklamalar |
|---|---|
| (  ) 15. Tokenization | A) Scikit-Learn'de TF-IDF ağırlıklarını hesaplayan sınıf |
| (  ) 16. Trigram | B) Cümlenin kelime, karakter ya da alt kelime gibi en küçük birimlere ayrılması |
| (  ) 17. Coherence score | C) Yapılandırılmamış metinlerden örüntü, tema ve içgörü çıkarma süreci |
| (  ) 18. TfidfVectorizer | D) "müşteri hizmetleri desteği" gibi üçlü kelime öbeği |
| (  ) 19. Metin madenciliği | E) LDA'da konu sayısı k seçilirken kullanılan tutarlılık ölçütü |

kampuscepte.com.tr

# 3. ünite · Cevap Anahtarı ve Açıklamalar

**1.** D · **2.** B · **3.** E · **4.** C · **5.** A · **6.** D · **7.** B · **8.** E · **9.** D · **10.** Y · **11.** D · **12.** D · **13.** Y · **14.** Y · **15.** B · **16.** D · **17.** E · **18.** A · **19.** C

| Soru | Doğru cevap | Açıklama |
|---|---|---|
| 1 | D) Cümlenin duygu yönü tersine dönebilir | "iyi değil" → "iyi": olumsuz yorum olumlu görünür. |
| 2 | B) Korunmaları veya metin etiketine dönüştürülmeleri | Emojiler yüksek polarite (duygu) bilgisi taşır. |
| 3 | E) Lemmatization | — |
| 4 | C) Kural tabanlı ek kesme yaptığı için daha hızlıdır | — |
| 5 | A) Kelime sırasını ve anlam bağlamını dikkate alır | BoW sırayı ve bağlamı dikkate almaz. |
| 6 | D) 0 | IDF = log(10/10) = log 1 = 0 → her yerde geçen kelime ayırt edici değildir. |
| 7 | B) Kelime kümeleri üretir; başlığı araştırmacı belirler | — |
| 8 | E) Kelimelerin hangi duygu yönünde kullanıldığını göstermez | — |
| 9 | DOĞRU [D] | İfade doğrudur. |
| 10 | YANLIŞ [Y] | Bigram "iyi değil"i tek öbek olarak yakalar; unigram ayırır. |
| 11 | DOĞRU [D] | İfade doğrudur. |
| 12 | DOĞRU [D] | İfade doğrudur. |
| 13 | YANLIŞ [Y] | Orange sürükle-bırak bloklarıyla kod yazmadan çalışır. |
| 14 | YANLIŞ [Y] | Özel isim/marka analizinde küçük harf dönüşümünün amaca uygunluğu değerlendirilmelidir. |
| 15 | B ile eşleşir | Tokenization → Cümlenin kelime, karakter ya da alt kelime gibi en küçük birimlere ayrılması |
| 16 | D ile eşleşir | Trigram → "müşteri hizmetleri desteği" gibi üçlü kelime öbeği |
| 17 | E ile eşleşir | Coherence score → LDA'da konu sayısı k seçilirken kullanılan tutarlılık ölçütü |
| 18 | A ile eşleşir | TfidfVectorizer → Scikit-Learn'de TF-IDF ağırlıklarını hesaplayan sınıf |
| 19 | C ile eşleşir | Metin madenciliği → Yapılandırılmamış metinlerden örüntü, tema ve içgörü çıkarma süreci |

kampuscepte.com.tr